# 센서 590개의 측정값으로 불량 웨이퍼를 미리 가려낼 수 있는가

**팀 수율 · 10101 홍길동 · 10102 김영희 · 10103 이철수**

당곡고등학교 데이터 과학 팀 프로젝트 · 2026

선생님이 만든 가상 팀의 샘플 · 데이터와 수치는 실제 계산값

저장소

## 1. 서론

**연구 질문: 공정 센서 값으로 불량 웨이퍼를 미리 가려낼 수 있는가**

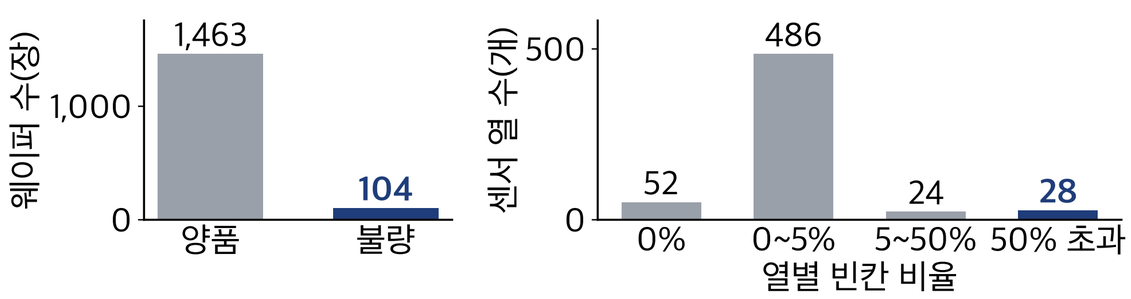
- 뉴스에서 자주 듣는 반도체 수율(양품의 비율)에서 출발
- 수업의 뇌졸중 데이터: 정확도가 높아도 환자를 거의 찾지 못함
- 불량이 **6.6%**뿐인 공장 데이터에서도 같은 일이 생기는가

**이 포스터:** 불량을 가려내는 분류 모델 다섯 개와 기준선의 비교, 그 해석과 한계

## 2. 데이터

**출처·크기:** UCI SECOM(2008년) · **1,567행 · 592열**

| 사용한 열 | 뜻 | 값 |
|---|---|---|
| fail | 판정(예측할 값) | 양품 1,463 · 불량 104 |
| sensor_001~590 | 센서 측정값(입력) | 590개 중 446개 사용 |
| timestamp | 측정 시각(분할 확인용) | 7월 19일~10월 17일 |




왼쪽: 판정별 웨이퍼 수 · 오른쪽: 열별 빈칸 비율(센서 칸 924,530개 중 빈칸 41,951개)

- 모든 행이 같은 값인 상수 열 **116개** 제거: 구분할 정보가 없음
- 빈칸이 절반을 넘는 열 **28개** 제거(빈칸 50.7%~91.2%) → **446개**
- 남은 빈칸 **10,868개**는 학습 데이터의 열별 중앙값으로 채움

## 3. 방법

**수집**(1,567장) → **변수 선택**(센서) → **전처리**(446열·표준화) → **분할**(층화·시간 순) → **기준선**(0.933) → **후보 모델 5종 비교** → **선택**(F1) → **평가**(재현율) → **해석**(상관·시기)

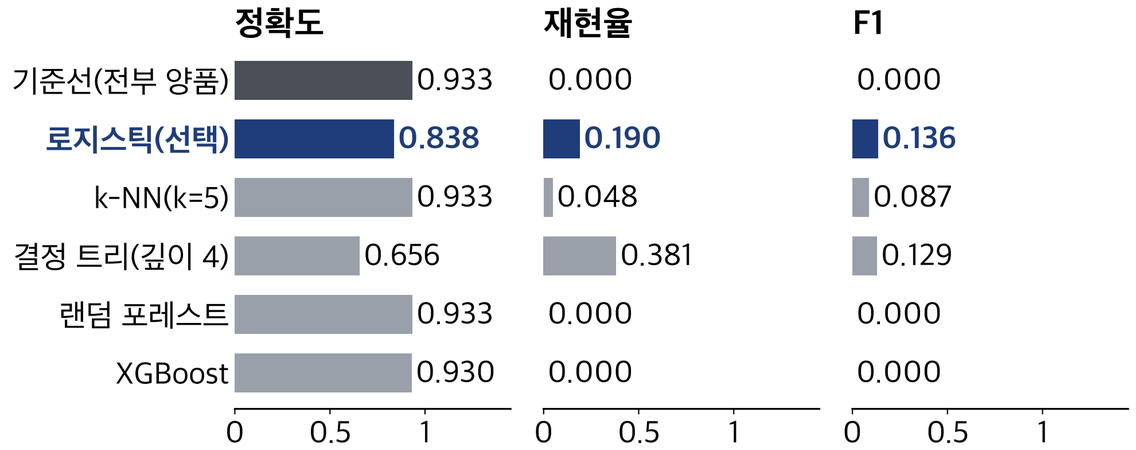
| 후보 모델(시험 314장, 불량 21장) | 정확도 | 재현율 | F1 | 잡은 불량 |
|---|---|---|---|---|
| 기준선(전부 양품) | 0.933 | 0.000 | 0.000 | 0장 |
| **로지스틱 회귀(가중치 켬, 선택)** | **0.838** | **0.190** | **0.136** | **4장** |
| k-NN(k=5, 가중치 없음) | 0.933 | 0.048 | 0.087 | 1장 |
| 결정 트리(깊이 4, 가중치 켬) | 0.656 | 0.381 | 0.129 | 8장 |
| 랜덤 포레스트(300그루, 가중치 켬) | 0.933 | 0.000 | 0.000 | 0장 |
| XGBoost(기본값, 가중치 켬) | 0.930 | 0.000 | 0.000 | 0장 |

- 정확도로 기준선을 넘은 모델이 없어 F1이 가장 높은 로지스틱 회귀 선택
- 센서마다 계수가 나와 판정 방향을 설명할 수 있음

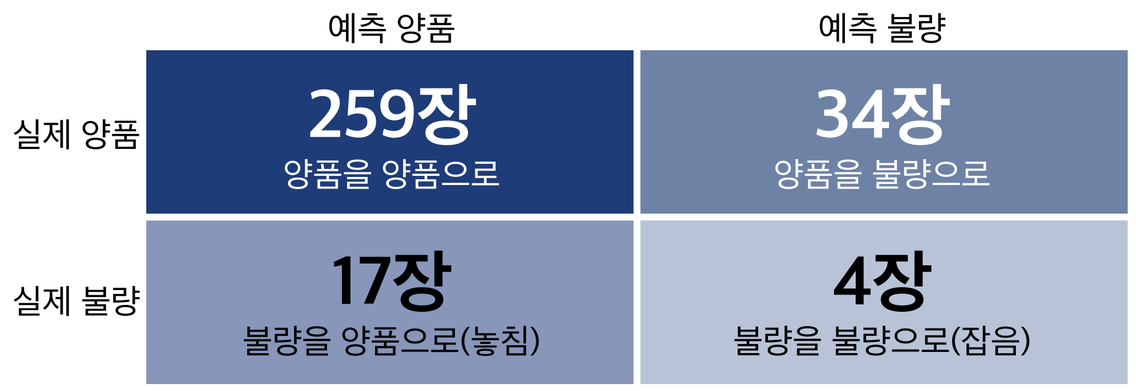
| 모델 | 원리 | 장점 | 단점 | 이런 상황에 좋다 | 우리 데이터 결과 |
|---|---|---|---|---|---|
| **로지스틱 (선택)** | **계수 합을 확률로 바꿔 판정** | **계수로 판정 방향 확인** | **복잡한 관계에 약함** | **이유 설명이 필요할 때** | **재현율 0.190 F1 0.136** |
| **결정 트리 (비교 1)** | 센서 값 질문으로 차례로 나눔 | 판정 규칙을 그대로 읽음 | 불량 판정 과다 | 규칙 확인이 필요할 때 | 재현율 0.381 양품 95장 오판 |
| **XGBoost (비교 2)** | 오차를 줄이는 트리를 차례로 더함 | 정확도가 높은 편 | 다수 범주로 쏠림 | 정확도가 중요할 때 | 정확도 0.930 재현율 0 |

- **정확도** 맞힌 비율 · **재현율** 실제 불량 중 잡은 비율 · **정밀도** 불량 판정 중 실제 불량 비율 · **F1** 정밀도와 재현율을 함께 반영
- **재현율 중심:** 놓친 불량은 그대로 출하되므로 잡은 비율을 먼저 봄

## 4. 결과




시험 데이터 314장(불량 21장) 기준 · 정확도 0.93대인 세 모델은 불량을 0~1장만 잡음




로지스틱 회귀(가중치 켬)의 혼동행렬 · 불량 21장 중 17장을 양품으로 판정

**0.190**
재현율(불량 21장 중 4장)

**0.838**
정확도(기준선은 0.933)

**0개**
정확도로 기준선을 넘은 후보 모델

## 5. 해석과 결론

정확도 0.838은 기준선(0.933)보다 **0.096** 낮고, 불량 21장 중 **4장**만 잡음.
랜덤 포레스트의 정확도 0.933은 314장 모두를 양품이라고 답한 결과.

**우리 팀이 찾아낸 것**

- **불량과 함께 움직이는 센서 없음:** 센서 446개 중 최대 상관 0.156, 0.2를 넘는 센서 0개
- **불량은 시기에 몰림:** 7~8월 10.5%, 9~10월 4.1% · 8월 10일은 하루 12장 중 5장
- **많이 잡은 모델이 양품도 많이 버림:** 불량 1장당 양품 결정 트리 11.9장, 로지스틱 8.5장
- **시간 순 분할로 다시 확인:** 불량 17장 중 3장, 결론은 같음

**이 데이터에서는 센서 값으로 불량을 미리 가려내기 어렵고, 불량률은 시기에 따라 크게 달라짐.**

## 6. 한계와 향후 연구

- 센서 590개의 이름과 단위가 비공개: 어느 공정이 원인인지 말할 수 없음
- 불량 104장(학습 83장)뿐이라 불량 한 장마다 재현율이 **0.048**씩 바뀜
- 2008년 한 공장의 약 석 달치: 다른 공장·지금의 공정에 적용 불가
- **오용 주의:** 실제 라인에 사용하면 양품 34장을 버리고 불량 17장을 내보냄
- **더 해 볼 것:** 불량 데이터 추가 수집, 불량이 몰린 7월 말~8월의 공정 기록 확인
- **교과·진로:** 화학·물리학·수학(조건부 확률) · 반도체 공정·품질 관리 엔지니어
- **배운 점:** 정확도가 가장 높은 모델도 혼동행렬을 직접 확인해야 함

데이터: McCann, M. & Johnston, A. (2008). SECOM [Dataset]. UCI Machine Learning Repository. doi.org/10.24432/C54305 (CC BY 4.0), 2026-10-15 접근

모든 수치는 code/check.py로 다시 계산 가능 · 데이터 출처·소프트웨어는 저장소 README 참고문헌 참고

저장소 github.com/greatsong/ds-sample-4-semiconductor · 앱 greatsong.github.io/ds-sample-4-semiconductor

앱