센서 590개의 측정값으로 불량 웨이퍼를 미리 가려낼 수 있는가

팀 수율 · 10101 홍길동 · 10102 김영희 · 10103 이철수

당곡고등학교 데이터 과학 팀 프로젝트 · 2026

선생님이 만든 가상 팀의 샘플 · 데이터와 수치는 실제 계산값

저장소

1. 서론

연구 질문: 공정 센서 값으로 불량 웨이퍼를 미리 가려낼 수 있는가

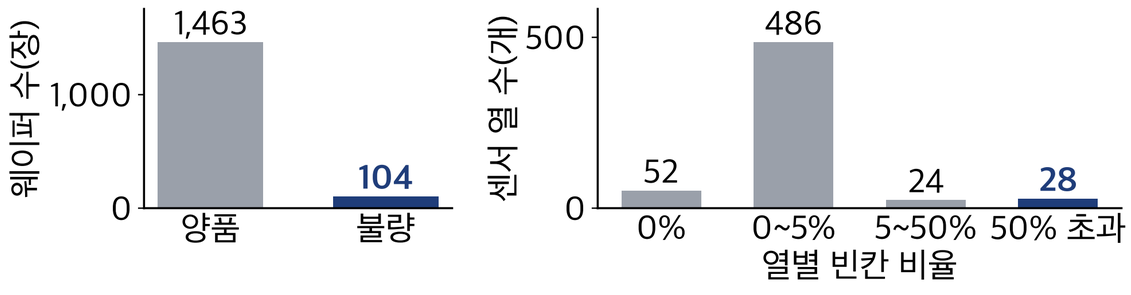
- 뉴스에서 자주 듣는 반도체 수율(양품의 비율)에서 출발
- 12차시 뇌졸중 데이터: 정확도가 높아도 환자를 거의 찾지 못함
- 불량이 **6.6%**뿐인 공장 데이터에서도 같은 일이 생기는가

이 포스터: 불량을 가려내는 분류 모델 다섯 개와 기준선의 비교, 그 해석과 한계

2. 데이터

출처·크기: UCI SECOM(2008년) · **1,567행 · 592열**

사용한 열	뜻	값
fail	판정(예측할 값)	양품 1,463 · 불량 104
sensor_001~590	센서 측정값(입력)	590개 중 446개 사용
timestamp	측정 시각(분할 확인용)	7월 19일~10월 17일



왼쪽: 판정별 웨이퍼 수 · 오른쪽: 열별 빈칸 비율(센서 칸 924,530개 중 빈칸 41,951개)

- 모든 행이 같은 값인 상수 열 **116개** 제거: 구분할 정보가 없음
- 빈칸이 절반을 넘는 열 **28개** 제거(빈칸 50.7%~91.2%) → **446개**
- 남은 빈칸 **10,868개**는 학습 데이터의 열별 중앙값으로 채움

3. 방법

승인 → **전처리** → **기준선** → **후보 모델** → **선택** → **해석**

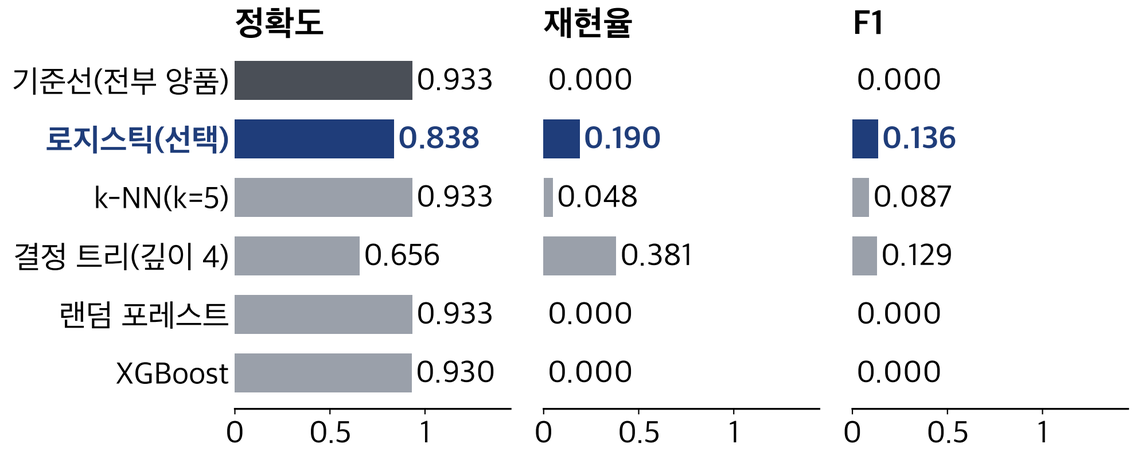
후보 모델(시험 314장, 불량 21장)	정확도	재현율	F1	잡은 불량
기준선(전부 양품)	0.933	0.000	0.000	0장
로지스틱 회귀(가중치 켬, 선택)	**0.838**	**0.190**	**0.136**	**4장**
k-NN(k=5, 가중치 없음)	0.933	0.048	0.087	1장
결정 트리(깊이 4, 가중치 켬)	0.656	0.381	0.129	8장
랜덤 포레스트(300그루, 가중치 켬)	0.933	0.000	0.000	0장
XGBoost(기본값, 가중치 켬)	0.930	0.000	0.000	0장

- 정확도로 기준선을 넘은 모델이 없어 F1이 가장 높은 로지스틱 회귀 선택
- 센서마다 계수가 나와 판정 방향을 설명할 수 있음

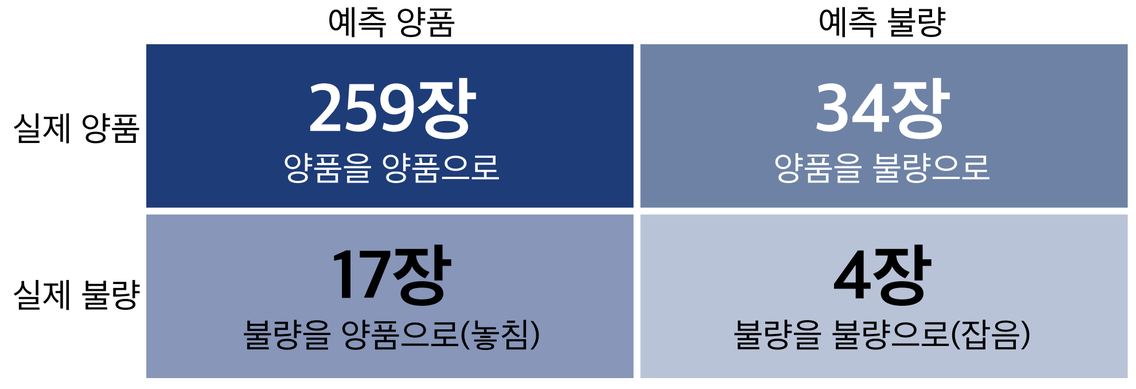
모델	원리	장점	단점	이런 상황에 좋다	우리 데이터 결과
로지스틱 (선택)	**계수 합을 확률로 바꿔 판정**	**계수로 판정 방향 확인**	**복잡한 관계에 약함**	**이유 설명이 필요할 때**	**재현율 0.190 F1 0.136**
결정 트리 (비교 1)	센서 값 질문으로 차례로 나눔	판정 규칙을 그대로 읽음	불량 판정 과다	규칙 확인이 필요할 때	재현율 0.381 양품 95장 오판
XGBoost (비교 2)	오차를 줄이는 트리를 차례로 더함	정확도가 높은 편	다수 범주로 쏠림	정확도가 중요할 때	정확도 0.930 재현율 0

- **정확도** 맞힌 비율 · **재현율** 실제 불량 중 잡은 비율 · **정밀도** 불량 판정 중 실제 불량 비율 · **F1** 정밀도와 재현율을 함께 반영
- **재현율 중심:** 놓친 불량은 그대로 출하되므로 잡은 비율을 먼저 봄

4. 결과



시험 데이터 314장(불량 21장) 기준 · 정확도 0.93대인 세 모델은 불량을 0~1장만 잡음



로지스틱 회귀(가중치 켬)의 혼동행렬 · 불량 21장 중 17장을 양품으로 판정

0.190
재현율(불량 21장 중 4장)

0.838
정확도(기준선은 0.933)

0개
정확도로 기준선을 넘은 후보 모델

5. 해석과 결론

최종 모델의 정확도 0.838은 모두 양품이라고 답하는 기준선(0.933)보다 **0.096** 낮음. 실제 불량 21장 가운데 **4장**만 잡았고, 불량으로 판정한 38장 가운데 34장은 양품이었음. 랜덤 포레스트는 정확도가 기준선과 같은 0.933이지만 314장 모두를 양품이라고 답함. 불량이 드문 데이터에서는 정확도가 높아도 불량을 잡았다는 근거가 되지 않음.

- **AI 반론 1:** "정확도 87%면 괜찮다" → 기준선 0.933보다 낮음, 모든 결과를 기준선과 나란히 적음
- **AI 반론 2:** 시간 순으로 나눠 다시 확인 → 불량 17장 중 3장, 결론은 같음

정확도 93%는 아무것도 하지 않은 것과 같고, 이 데이터로는 불량을 미리 가려내기 어려움.

6. 한계와 향후 연구

- 센서 590개의 이름과 단위가 비공개: 어느 공정이 원인인지 말할 수 없음
- 불량 104장(학습 83장)뿐이라 불량 한 장마다 재현율이 **0.048**씩 바뀜
- 2008년 한 공장의 약 석 달치: 다른 공장·지금의 공정에 적용 불가
- **오용 주의:** 실제 라인에 사용하면 양품 34장을 버리고 불량 17장을 내보냄
- **더 해 볼 것:** 불량 데이터 추가 수집, 센서 이름이 공개된 데이터로 원인 찾기
- **교과·진로:** 화학·물리학·수학(조건부 확률) · 반도체 공정·품질 관리 엔지니어
- **배운 점:** 정확도가 가장 높은 모델도 혼동행렬을 직접 확인해야 함

데이터: McCann, M. & Johnston, A. (2008). SECOM [Dataset]. UCI Machine Learning Repository. doi.org/10.24432/C54305 (CC BY 4.0), 2026-10-15 접근
모든 수치는 code/check.py로 다시 계산 가능 · 데이터 출처·소프트웨어는 저장소 README 참고문헌 참고
저장소 github.com/greatsong/ds-sample-4-semiconductor · 앱 greatsong.github.io/ds-sample-4-semiconductor

앱